

Automatsko generisanje opisa slika primenom CNN i LSTM mreža

Nebojša Vuga
Fakultet tehničkih nauka
Univerzitet u Novom Sadu
Novi Sad, Srbija
R2 23/2024

Bogdan Janošević
Fakultet tehničkih nauka
Univerzitet u Novom Sadu
Novi Sad, Srbija
R2 43/2024

Apstrakt - Automatsko generisanje opisa slika predstavlja zadatak u kome se za datu sliku formira odgovarajući opis na prirodnom jeziku, što zahteva povezivanje vizuelnih informacija i jezičkog modelovanja. U ovom radu prikazana je implementacija i evaluacija arhitekture tipa koder dekodeer zasnovane na CNN i LSTM mrežama na skupu podataka Flickr30k. Kao vizuelni koder koristi se prethodno obučeni model ResNet50, dok jedan LSTM sloj generiše opis reč po reč. Upoređena su dva modela u sistemu: osnovni model sa fiksiranim težinama ResNet50 mreže i model kod koga se poslednji slojevi ResNet50 dodatno prilagođavaju (fine tuning) zadatku generisanja opisa. Osnovni model evaluiran je na podskupovima od 3k, 15k i 25k slika korišćenjem metrika BLEU, ROUGE (1, 2, L) i METEOR. Za model sa dodatnim prilagođavanjem sprovedena je pretraga hiperparametara po stopi učenja i broju odmrznutih CNN slojeva. Rezultati pokazuju da osnovni model najbolje rezultate postiže na 15k slika (BLEU=0.136, METEOR=0.300), dok model sa dodatnim prilagođavanjem, sa 30 odmrznutih slojeva, u pretrazi hiperparametara ostvaruje najmanji gubitak na validacionom skupu od 4.167. Model sa dodatnim prilagođavanjem ostvaruje bolje vrednosti ROUGE i METEOR metrika na test skupu.

I. UVOD

Automatsko generisanje opisa slika je oblast koja povezuje računarski vid i obradu prirodnog jezika. Cilj je da se na osnovu sadržaja slike automatski formira smislen tekstualni opis. Ovakvi sistemi imaju široku primenu, od unapređenja pristupačnosti digitalnog sadržaja za korisnike sa oštećenjem vida, do boljeg pretraživanja i indeksiranja velikih kolekcija slika na društvenim mrežama i u digitalnim arhivama.

Glavni izazov ovog zadatka jeste povezivanje dva različita tipa podataka: vizuelnog sadržaja slike i jezičkog opisa. Sa razvojem dubokog učenja, ovaj problem se najčešće rešava kombinovanjem konvolutivnih neuronskih mreža (CNN), koje izdvajaju vizuelne karakteristike, i rekurentnih mreža, naročito LSTM mreža, koje generišu tekstualni opis. Uobičajen pristup podrazumeva da CNN mreža iz slike izvuče vektor karakteristika, koji se zatim prosleđuje LSTM mreži kako bi se opis generisao reč po reč.

Zahvaljujući velikim obučanim modelima kao što su ResNet50, VGG i Inception, vizuelni deo sistema danas se često zasniva na prenosu znanja sa nekog već rešenog zadatka, najčešće klasifikacije slika na skupu ImageNet. Takvi modeli mogu da se koriste na dva načina: ili se njihove težine

ostavljaju nepromenjene, ili se dodatno prilagođavaju konkretnom zadatku generisanja opisa.

U ovom radu ispitujemo sledeće pitanje: koliki je uticaj dodatnog prilagođavanja modela ResNet50 na kvalitet generisanih opisa i koja kombinacija hiperparametara daje najbolje rezultate na skupu Flickr30k. Implementirane su obe varijante sistema. Model sa fiksiranim vizuelnim koderom kao i model sa dodatnim prilagođavanjem, a zatim je sprovedena evaluacija na više veličina skupa podataka.

II. PREGLED LITERATURE

A. Primena CNN i LSTM mreža u generisanju opisa slika

Ovaj rad [1] predstavlja reprezentativan pristup koji kombinuje CNN i LSTM mreže za generisanje opisa slika na skupu Flickr8k (oko 8 hiljada slika, sa po pet opisa za svaku sliku). CNN mreža izdvaja karakteristike slike, dok LSTM dekodeer na osnovu njih generiše tekstualni opis. Model je evaluiran pomoću metrike BLEU i ostvaruje tačnost opisa od 80-90%. Ovaj rad potvrđuje da arhitektura CNN+LSTM predstavlja dobru osnovu za ovakav tip zadatka i daje motivaciju da se ista ideja primeni na većem i zahtevnijem skupu Flickr30k, uz detaljniji postupak evaluacije.

B. ClipCap pristup za generisanje opisa slika

Rad [2] predlaže pristup ClipCap, u kome se prethodno obučeni modeli CLIP i GPT-2 povezuju preko male mreže za mapiranje, koja se trenira specifično za zadatak generisanja opisa, dok osnovni modeli ostaju nepromenjeni. ClipCap ostvaruje dobre rezultate na skupovima COCO i Conceptual Captions prema metrikama BLEU, CIDEr, ROUGE-L, SPICE i METEOR. Najvažniji zaključak ovog rada jeste da i relativno mali broj parametara specifičnih za zadatak može da donese veoma dobre rezultate kada se polazi od kvalitetnih prethodno obučanih modela. Koriste se metrike koje se koriste i u okviru ovog istraživanja.

III. METODOLOGIJA I IMPLEMENTACIJA

A. Skup podataka

Skup podataka Flickr30k sadrži 31.783 slike prikupljene sa platforme Flickr. Svaka slika ima po pet opisa na engleskom jeziku koje su pisali ljudi i koji opisuju prikazanu scenu. Skup obuhvata veliki broj svakodnevnih situacija, ljudi, životinja i predmeta. Dužina opisa kreće se od 2 do približno 70 reči, dok je uobičajena dužina između 12 i 15 reči.

U svim eksperimentima korišćena je podela skupa podataka: 70% za trening, 20% za validaciju i 10% za testiranje, uz seed=3. Osnovni model sa fiksiranim ResNet50 koderom evaluiran je na tri trening podskupa: 3k, 15k i 25k slika, pri čemu je za svaki podskup korišćena podela 70/20/10 uz seed 3. Model sa dodatnim prilagođavanjem treniran je na 15k slika, jer se taj podskup pokazao kao najbolji u eksperimentima sa osnovnim modelom.

B. Predobrada podataka

Sve slike su skalirane na veličinu od 224×224 piksela. Nakon toga je nad njima primenjena Keras funkcija **Preprocess_input** za model ResNet50, kako bi slike bile pripremljene u formatu koji odgovara prethodno istreniranom modelu. Opisi su očišćeni uklanjanjem interpunkcijskih znakova, prebaćeni u mala slova i sređeni tako da se višestruki razmaci zamene jednim. Na početak i kraj svakog opisa dodati su specijalni tokeni **startseq** i **endseq**. Zatim je formirano preslikavanje između naziva slike i pripadajućih opisa, pri čemu su zadržane samo one slike koje postoje i u skupu slika i u fajlu sa opisima.

C. Arhitektura modela

Sistem se zasniva na modelu za generisanje opisa slika koji kombinuje vizuelne karakteristike slike i jezički kontekst prethodno generisanog teksta. Model se sastoji od dve paralelne grane: vizuelne i jezičke. Vizuelna grana koristi prethodno obučeni model ResNet50 sa težinama naučenim na skupu ImageNet, bez završnog klasifikacionog sloja. Za svaku sliku izdvaja se vektor karakteristika dimenzije 2048. Ovaj vektor zatim prolazi kroz Dropout sloj sa stopom 0,5 i potpuno povezani sloj koji ga projektuje na 256 dimenzija uz ReLU aktivaciju. Jezička grana kao ulaz prima delimično generisan opis slike. Ulazna sekvenca se najpre preslikava u vektorske reprezentacije pomoću Embedding sloja dimenzije 256, nakon čega sledi Dropout sloj sa stopom 0,5 i LSTM sloj sa 256 jedinica, koji modeluje kontekst sekvence.

Izlazi vizuelne i jezičke grane zatim se spajaju sabiranjem po elementima i prosleđuju kroz gusti sloj sa 256 jedinica i ReLU aktivacijom. Na kraju, izlazni sloj sa softmax aktivacijom predviđa narednu reč iz rečnika. Model se trenira korišćenjem funkcije greške sparse categorical cross-entropy i Adam optimizatora.

D. Osnovni model sa fiksiranim koderom

Kod osnovnog modela težine ResNet50 mreže ostaju nepromenjene tokom celog treninga. Karakteristike slika izdvajaju se unapred i čuvaju kao .npz fajlovi, čime se smanjuje vreme treniranja. Deo modela zadužen za generisanje opisa trenira se primenom pristupa *teacher forcing*. Kod ovog pristupa, u svakom koraku model kao ulaz dobija tačnu prethodnu reč iz referentnog opisa, dok je cilj da predvidi narednu reč u sekvenci. Za optimizaciju parametara koristi se Adam optimizator sa stopom učenja 0.001. U fazi generisanja opisa koristi se pohlepno generisanje opisa. To znači da se u svakom koraku bira reč sa najvećom prediktovanom verovatnoćom.

E. Model sa dodatnim prilagođavanjem

U drugoj varijanti sistema poslednji slojevi ResNet50 mreže odmrzavaju se i zajedno treniraju sa delom modela za generisanje opisa. Broj odmrznutih slojeva određen je parametrom *cnn_trainable_layers*. Da bi se izbegla nestabilnost pri učenju, svi Batch Normalization slojevi ostaju zamrznuti. Za optimizaciju se koristi Adam optimizator, pri čemu je u okviru eksperimenata ispitivano više vrednosti stope učenja. Trening se realizuje pomoću generatora podataka koji u hodu učitava i obrađuje slike, primenjujući istu normalizaciju kao i kod osnovnog modela. Rano zaustavljanje sa strpljenjem 2 prati gubitak na validacionom skupu i čuva najbolju verziju modela.

F. Metrike evaluacije

Tokom istraživanja korišćene su tri standardne metrike za evaluaciju kvaliteta generisanih opisa:

BLEU meri preciznost n-grama generisanih opisa u odnosu na referentne opise. Izračunava se pomoću NLTK funkcije *corpus_bleu*, sa podrazumevanom geometrijskom sredinom preciznosti od 1-grama do 4-grama.

ROUGE (1, 2, L) meri preklapanje n-grama kao i najdužu zajedničku podsekvencu između generisanog i prvog referentnog opisa.

METEOR kombinuje preciznost i odziv kroz harmonijsku sredinu, a dodatno uzima u obzir i semantičku sličnost reči preko WordNet baze, pa bolje odražava semantičku sličnost od BLEU metrike.

IV. REZULTATI I DISKUSIJA

A. Rezultati osnovnog modela za različite veličine skupa

Tabela 1 prikazuje rezultate osnovnog CNN+LSTM modela sa fiksiranim vizuelnim koderom za tri veličine trening podskupa.

Tabela 1. Osnovni CNN+LSTM model sa fiksiranim ResNet50 koderom.

Trening (k)	BLEU	R-1	R-2	R-L	METEOR
3	0.083	0.264	0.072	0.228	0.283
15	0.136	0.251	0.075	0.232	0.300
25	0.107	0.254	0.078	0.224	0.281

Rezultati pokazuju jasno poboljšanje performansi pri prelasku sa 3k na 15k slika, što se vidi kroz rast BLEU i METEOR metrika. Međutim, pri 25k slika dolazi do pada rezultata (BLEU: 0.107; METEOR: 0.281) u odnosu na najbolju konfiguraciju sa 15k slika. Moguće objašnjenje je to što vizuelni koder ostaje fiksiran, pa LSTM deo modela, iako vidi više trening primera, ne dobija dovoljno prilagođene vizuelne reprezentacije za raznovrsniji skup scena. Zbog toga se 15k pokazuje kao najbolji kompromis za osnovni model.

B. Pretraga hiperparametara za model sa dodatnim prilagođavanjem

Sprovedena je pretraga po dva hiperparametra: stopi učenja Adam optimizatoru i broju odmrznutih slojeva ResNet50 mreže (10, 20 ili 30). Svih šest konfiguracija trenirano je po 5 epoha na 15k slika, uz batch size 8. Tabela 2 prikazuje najmanji gubitak na validacionom skupu zabeležen za svaku konfiguraciju.

Tabela 2. Pretraga hiperparametara - gubitak na validacionom skupu za model sa dodatnim prilagođavanjem. Najbolji rezultat je podebljan.

Stopa učenja	Odmrznuti CNN slojevi	Najmanji val. gubitak
0.00005	10	4.382
0.00005	20	4.350
0.00005	30	4.316
0.0001	10	4.238
0.0001	20	4.192
0.0001	30	4.167

U svim eksperimentima vidi se isti trend: viša stopa učenja i veći broj odmrznutih slojeva dovode do manjeg gubitka na validacionom skupu. Najbolji rezultat postiže konfiguracija sa 30 odmrznutih slojeva i stopom učenja 0.0001, gde je minimalni validacioni gubitak 4.167. Ovakav rezultat ukazuje da se dodatnim prilagođavanjem dubokih slojeva ResNet50 mreže dobijaju karakteristike koje su bolje usklađene sa sadržajem slika u skupu Flickr30k. Niža stopa učenja

verovatno nije dovoljna da u samo pet epoha omogući veće prilagođavanje modela zadatku.

C. Poređenje osnovnog i dodatno prilagođenog modela

Tabela 3 prikazuje poređenje osnovnog modela sa fiksiranim ResNet50 koderom (15k slika, najbolja konfiguracija) i modela sa najboljim podešavanjima za dodatno prilagođavanje (30 odmrznutih slojeva). BLEU, ROUGE i METEOR su korišćeni za poređenje.

Tabela 3. Poređenje osnovnog i dodatno prilagođenog CNN+LSTM modela na test skupu (15k slika).

Model	BLEU	R-1	R-2	R-L	METEOR
Osnovni model	0.136	0.251	0.075	0.232	0.300
Fine-tuned	0.133	0.263	0.081	0.240	0.322

Model sa dodatnim prilagođavanjem ostvaruje bolje rezultate po svim metrikama osim BLEU. Posebno je značajno poboljšanje METEOR metrike, jer ona bolje odražava semantičku sličnost od BLEU. To ukazuje da dodatno prilagođavanje omogućava vizuelnom koderu da izvuče korisnije karakteristike za zadatak generisanja opisa, umestoda se oslanja samo na opšte obrasce naučene na skupu ImageNet.

D. Kvalitativna analiza

Tabela 4 prikazuje nekoliko primera generisanih opisa. Vrednosti BLEU-1 i METEOR izračunate su u odnosu na svih pet referentnih opisa, dok je u tabeli prikazan samo jedan reprezentativan referentni opis.

Tabela 4. Primeri generisanih opisa - dodatno prilagođeni model (15k slika).

Kategorija	Slika	Generisani opis	Referentni opis	BLEU-1	METEOR
Dobar primer	2180480870.jpg	a dog is running through the grass	a dog runs through the grass	1.000	0.965
Dobar primer	3471173526.jpg	a group of people are sitting at a table	a group of people are sitting around a table conversing	1.000	0.802
Srednji primer	3084149186.jpg	a man in a blue shirt is a rock wall	a man is holding onto the underside of an outcropping while rock	0.800	0.372

			climbing		
Srednji primer	1928319708.jpg	a man in a blue shirt is riding a bike on a bike	a man rides his bicycle on a wet road	0.538	0.396
Loš primer	2536853135.jpg	a man in a black shirt is standing in front of a building	two construction workers wearing orange vests	0.154	0.083
Loš primer	2101755951.jpg	a man in a black shirt is standing in front of a man in a black shirt	three asian men running and winning a race	0.222	0.093

Primeri pokazuju dva tipična obrasca grešaka ove CNN+LSTM arhitekture. Prvi je sklonost ka generičkim rečenicama, kao što su “a man in a black shirt is standing” ili slične formulacije koje se često pojavljuju u trening podacima. Takvi opisi su gramatički korektni, ali često ne prenose dovoljno konkretnih informacija o slici. Drugi obrazac je da model mnogo bolje radi na jednostavnijim i vizuelno jasnim scenama, naročito kada su na slici životinje ili jasno izražene radnje. U takvim slučajevima vizuelne karakteristike izdvojene ResNet50 mrežom daju dovoljno informacija da opis bude relativno precizan. Iako dodatno prilagođeni model ne rešava u potpunosti problem generičkih opisa, prikazani primeri pokazuju da može da generiše tačne opise kod jednostavnijih i vizuelno jasnijih scena.

V. ZAKLJUČAK

U radu je prikazana implementacija i evaluacija sistema za automatsko generisanje opisa slika zasnovanog na CNN+LSTM arhitekturi, uz poređenje dve varijante: osnovnog modela sa fiksiranim ResNet50 koderom i modela kod koga se ResNet50 dodatno prilagođava zadatku. Rezultati pokazuju da osnovni model najbolje performanse ostvaruje na podskupu od 15k slika, sa BLEU vrednošću 0.136 i METEOR vrednošću 0.300, dok pri većem broju slika dolazi do pada performansi. Sa druge strane, dodatno prilagođavanje poslednjih 30 slojeva ResNet50 mreže uz stopu učenja 0.0001 dovodi do manjeg gubitka na validacionom skupu i boljih ROUGE i METEOR vrednosti na test skupu, uz nešto nižu BLEU vrednost.

Na osnovu dobijenih rezultata može se zaključiti da dodatno prilagođavanje vizuelnog koda ima pozitivan uticaj na kvalitet generisanih opisa, jer model dobija reprezentacije koje su bolje prilagođene konkretnom skupu podataka. Ipak, sistem i dalje ima ograničenja u vidu generisanja suviše opštih i šablonskih rečenica.

Kao mogući pravci budućeg rada izdvajaju se uvođenje beam search pristupa umesto pohlepnog dekodiranja, dodavanje mehanizma pažnje nad prostornim CNN karakteristikama, kao i eksperimentisanje sa složenijim jezičkim dekodirima. Takođe, dodatna augmentacija podataka i duže treniranje mogli bi da doprinesu stabilnijem ponašanju modela na većim skupovima podataka.

VI. LITERATURA

- [1] Y. P. Singh et al., “Image Captioning using Artificial Intelligence” in J. Phys. Conf. Ser., vol. 1854, p. 012048, IOP Publishing, 2021.
- [2] R. Mokady, A. Hertz, and A. H. Bermano, “ClipCap: CLIP Prefix for Image Captioning,” arXiv preprint arXiv:2111.09734, 2021.